



Yann Maillot

INGÉNIEUR IA APPLIQUÉE & FULLSTACK · RAG — LLM — AGENTS — ML EMBARQUÉ

CONTACT

☎ +33 6 26 73 55 97
✉ yann.maillot.29@gmail.com
✦ Remote · Partout en France
in /in/yann-maillot
gh @FelixDaCraft
➤ yann.aynn.fr

COMPÉTENCES IA

RAG : pipeline hybride BGE-M3 (dense + sparse + ColBERT) → Qdrant (fusion RRF) → reranking ColBERT ; génération encadrée, sourcée & citée

LLM : Mistral (souverain, temp. 0), OpenAI / Claude ; prompt engineering, structured output, garde-fous anti-hallucination & anti-injection, évaluation

Agents & orchestration : workflows multi-agents, serveurs MCP, outillage Claude Code (certifié Anthropic) / Cursor

ML appliqué : classification audio embarquée (YAMNet / TFLite, AudioSet), speech-to-text (Mistral)

Infra IA : FastAPI, Qdrant, Docker, self-hosting de modèles, Cloudflare Tunnel

STACK PRODUIT

Langages : Python, TypeScript, JavaScript, SQL, Java

Web : Next.js (App Router, RSC), React, Node.js, tRPC, PostgreSQL (Drizzle, Prisma), Stripe, Tailwind / shadcn

Reverse eng : Ghidra, Frida (protocoles propriétaires, chiffrement)

Ops : Docker / Compose, GitHub Actions (runners self-hosted), Linux (Debian), KVM, Nginx / Traefik

CERTIFICATIONS

Claude Code 101 ➤ · Claude 101 ➤ · Agent Skills
Anthropic Academy · 2026 · vérifiables

FORMATIONS

WebForce3 — Développeur Salesforce (2022)

Simplon.co — Développeur web (2017-2018)

Le 101 · IPI — programmation / info (2016-2017)

LANGUES

Français : natif · Anglais : technique

PRÉSENTATION

Développeur fullstack senior, ex-Accenture, spécialisé en **IA appliquée**. Je conçois et **j'opère mes propres produits IA en production** : un assistant RAG souverain qui ne peut pas inventer, des pipelines LLM (STT + journalisation structurée), de la détection ML embarquée. Je « **vibe code** » au quotidien — Claude Code, Cursor, orchestration multi-agents — mais je livre du **prod-grade** : je comprends le code sous le capot, je teste, je sécurise, je déploie. De l'idée au produit qui tourne tout seul.

PROJETS IA EN PRODUCTION

JLLM — assistant RAG souverain github.com/FelixDaCraft/JLLM ➤
Réponses **sourcées & citées**, 99 % de fidélité au texte, 7/7 aux tests d'injection · BGE-M3 → Qdrant (RRF) → reranking → Mistral

Ringdo — journalisation LLM des appels github.com/FelixDaCraft/RingDo ➤
App Android native → backend · **STT Mistral** + structuration LLM (résumé, sujets, interlocuteurs) + recherche full-text

BabyMonitor — ML embarqué + reverse eng github.com/FelixDaCraft/v308-rtsp-hack ➤
Détection ML des pleurs (YAMNet TFLite) sur flux d'une caméra IP dont j'ai cassé le protocole (AES-128-ECB)

AUSSI EN PRODUCTION

CupMetrics · Platinum CBD Cup [platinum-cbd-cup](https://platinum-cbd-cup.com) ➤
SaaS événementiel multi-tenant · Stripe · anonymisation jury · 3D Three.js

Cabinet Psychologue [psy-cabinet](https://psy-cabinet.com) ➤
Site client livré clé en main · SEO local · back-office d'édition autonome

RÉSUMÉ EXPÉRIENCE

Freelance — IA appliquée & Fullstack 08/2023 →auj.
Conception & opération de 5 produits en prod · Next.js / Node / Python / PostgreSQL

Accenture France — Nantes 05/2022 — 07/2023
Développeur Salesforce · CDI · projet grand compte (Apex, LWC, Flows)

SQLI · Francecom · Yunow · 420 Green Road 2019 — 2022
Java/JEE (La Banque Postale), full-stack, Symfony, e-commerce (dropshipping)
Dolibarr/WordPress

PROJETS IA – DÉTAIL

PROJET	JLLM – assistant RAG souverain – github.com/FelixDaCraft/JLLM ↗
Problème	Un LLM qui ne peut pas mentir sur un corpus : chaque réponse doit être générée uniquement depuis le texte source , sourcée et vérifiable.
Ce que j'ai construit	➤ Retrieval hybride : embeddings BGE-M3 (dense + sparse + ColBERT) → Qdrant, fusion RRF, puis reranking ColBERT ➤ Génération encadrée par Mistral (souverain, température 0), réponses citées (chapitre · section) ➤ Garde-fous : refus systématique du hors-corpus, anti-injection (7/7 aux tests), ~99 % de fidélité mesurée ➤ API FastAPI + interface de chat, conteneurisé Docker, exposé via Cloudflare Tunnel, opéré sur homelab
Stack	Python · FastAPI · Qdrant · BGE-M3 · Mistral · Docker · Cloudflare Tunnel
PROJET	Ringdo – pipeline LLM appels – github.com/FelixDaCraft/RingDo ↗
Problème	Journaliser automatiquement chaque appel téléphonique, de l'audio brut à une fiche structurée exploitable.
Ce que j'ai construit	➤ App Android native (Java) qui surveille le dossier d'enregistrements et upload chaque fichier ➤ Speech-to-text Mistral sur l'audio, puis structuration par LLM (date, durée, interlocuteurs, résumé, sujets) en sortie structurée ➤ Recherche full-text sur l'historique · backend Node + PostgreSQL, Docker
Stack	Android natif · Java · Node.js · PostgreSQL · Mistral (STT + LLM) · Docker
PROJET	BabyMonitor – ML embarqué + reverse engineering – github.com/FelixDaCraft/v308-rtsp-hack ↗
Problème	Surveiller un bébé en temps réel depuis une caméra IP verrouillée sur son cloud propriétaire, avec alerte intelligente sur les pleurs.
Ce que j'ai construit	➤ Reverse engineering du protocole (Ghidra / Frida) : chiffrement AES-128-ECB, décodage H.264 / HEVC ➤ Détection ML embarquée des pleurs : YAMNet TFLite (classification audio AudioSet) ➤ PWA self-hostée + Web Push qui perce le mode silencieux iOS · Node, Docker, Traefik
Stack	Python · YAMNet TFLite · Node Express · go2rtc / ffmpeg · PWA Web Push · Docker
MÉTHODE	Ingénierie assistée par IA (« vibe coding » prod-grade)
Au quotidien	➤ Développement piloté par Claude Code / Cursor : prototypage rapide puis durcissement (types stricts, tests Vitest/Playwright, revue) ➤ Orchestration multi-agents : workflows d'agents spécialisés (design, dev, review) et serveurs MCP maison pour brancher les LLM sur mes outils/données ➤ Chaîne de livraison : un push = typecheck, tests, build Docker, migration, déploiement, healthcheck (CI/CD GitHub Actions, runners self-hosted) ➤ Conviction : l'IA accélère, mais la valeur est de livrer maintenable et sécurisé – pas d'accepter la sortie les yeux fermés
Dispo	Remote · partout en France · freelance ou CDI selon la mission